

Linear Regression笔记

线性回归就是有监督的回归

假设H: $H(x) = a + b * x$

同时还有 $h(x) = \sum_{j=0}^2 \theta_j * x_j$, 设置 $x_0 = 1$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}$$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$$

其中 θ 称为参数, 我们求解机器学习算法就是求解参数。

m=training example

x=input

y=output

$(x^{(i)}, y^{(i)})$ 是数据的一个训练样本, 上标区分训练样本, 下标区分样本特征。m作为样本数量, n作为特征数量

目标函数不仅仅取决于 θ 同时取决于样本 x , 因此函数等同于 $h_{\theta}(x)$

目标函数: $\min_{\theta} \frac{1}{2} \sum_{i=1}^n (h(x) - y)^2$

gradient descent(梯度下降)的变化取决于你初始化在哪。 $\theta_j := \theta_j - l * \frac{\partial J(x)}{\partial \theta_j}$, L为其学习率

批量梯度下降就是就是在整个训练集中批量处理整个数据, 但是其缺点为在极大的数据集中, 为了计算某一个指标的梯度, 可能是很小, 但是你却要扫描整个数据集。

随机梯度下降并不会达到收敛, 参数会震荡但永远不会收敛。为for i=1 to m

$\theta_j = \theta_j - l * (h(x^{(i)}) - y^{(i)}) * x^{(i)}$

但同时, 可以进行梯度下降结合随机梯度下降算法。

$$\text{正态方程: } \nabla J(\theta) = \begin{bmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \end{bmatrix}$$

$$\text{设计矩阵: } X * \theta = \begin{bmatrix} \dots (x^{(1)})^T \dots \\ \dots (x^{(2)})^T \dots \\ \dots (x^{(3)})^T \dots \end{bmatrix} * \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} h_1(x) \\ h_2(x) \\ \dots \end{bmatrix}$$

$$\text{对应向量: } y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \end{bmatrix}$$

因此有:

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

$$\text{等效于 } \frac{1}{2} (x\theta - y)^T (x\theta - y)$$

$$\text{正态方程最终结果是: } X^T X \theta = X^T y$$