

03

今天主讲局部加权线性回归去拟合非线性的方程，以及逻辑回归，牛顿逻辑回归，以及线性回归的概率解释

局部加权回归

对于不可以线性回归的数据，我们可以采取如下措施：

一、改变特征

比如说将 X_2 修改为 $\sqrt{X_2}$ ，从而返回第一个线性回归方程

二、局部加权线性回归和局部加权回归

局部加权回归(locally weight regression)

机器学习中分为参数学习算法和非参数学习算法，但是在参数学习算法中，适合于我们拥有固定的数据集，可以边做边删除这样。

如果输入 h 去预测 x ，对于线性回归来说，就是拟合 θ ，使得 $\min$ 成本函数

但对于局部加权回归，就是在 x 附近的数据集进行训练。

成本函数修正为： $\sum_{i=1}^m \omega^{(i)} (y^{(i)} - \theta^T x^{(i)})^2$ 其中 ω 为权重。

$$\omega^{(i)} = \exp\left(-\frac{(x^{(i)} - x)^2}{2}\right)$$

局部线性回归限制（也是大部分学习算法的限制）：往往只能在数据集内进行内推，外推误差将会极大。

对于误差项为什么采用平方误差

在上一堂课中，遗留问题，损失函数为什么不选择四次方亦或绝对值

今天将阐述逻辑回归。

假设数据集中符合 $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$ ，其中 ε 称为噪音。

同时假设 ε 服从标准正态分布，这表示为 $P(\varepsilon^{(i)}) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(\varepsilon^{(i)})^2}{2\sigma^2}\right)$

同时假设IID(independently, identically distributed)即独立同分布

因此可得 $P(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$ (可以联系到计量经济学), 这里的 θ 指的是参数化该概率。

the likelihood of theta 定义为数据的概率， $f(\theta) = P(y|x; \theta) = \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta)$, 参数的likelihood 等同于数据的概率

用最大似然估计求解似然函数：

"log likelihood"

$$\begin{aligned}
 \ell(\theta) &= \log L(\theta) \\
 &= \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp(\dots) \\
 &= \sum_{i=1}^m \left[\log \frac{1}{\sqrt{2\pi}\sigma} + \log \exp(\dots) \right] \\
 &= m \log \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^m - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}
 \end{aligned}$$

在似然估计的最终求解，也是一个平方的形式，因此选择平方项作为误差。

Classification 分类问题（二进制分类）

在这一部分数据集中， $y_i \in \{0, 1\}$

如果采取线性回归的方法，那么可以将0.5设置为一个阈值，大于0.5则为1，小于0.5则为0，解决该二分类问题。但是这并不是一个好的方法，易受异常值影响。

Logistic Regression(逻辑回归或者是对数回归)

want: $h_\theta(x) \in [0, 1]$

$$h_\theta(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

$g(z) = \frac{1}{1 + e^{-z}}$ 称为sigmoid\logistic function

假设：数据具有如下分布：

$$P(y = 1|x; \theta) = h_\theta(x)$$

$$P(y = 0|x; \theta) = 1 - h_\theta(x)$$

因此合并成如下方程组：

$$P(y|x; \theta) = h_\theta(x)^y (1 - h_\theta(x))^{1-y}$$

继续使用最大似然估计法进行参数估计：

$$l(\theta) = p(\vec{y} | x; \theta)$$

$$= \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta)$$

$$= \prod_{i=1}^m h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$$

$$L(\theta) = \log l(\theta)$$

$$= \sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1-y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))$$

Choose θ to maximize $L(\theta)$.

为使似然函数最大化，因此我们采取梯度上升方法：

$$\theta_j = \theta_j + \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

牛顿法

我们需要梯度下降多次迭代才能趋近收敛，但是采取牛顿法将会快速达到收敛。

即有一个函数 f ，参数为 θ ，约束条件为 $f(\theta) = 0$

在逻辑回归中，我们想要最大化似然函数，那么可以等效于求解其导数为0

即为 $\theta = \theta - df(\theta)/diff(df(\theta))$

牛顿法具有二次收敛性质

When Θ is a vector: ($\Theta \in \mathbb{R}^{n+1}$)

$$\Theta^{(t+1)} := \Theta^{(t)} + \underbrace{H^{-1} \nabla_{\Theta} \ell}_{\text{vector } \mathbb{R}^{n+1}}$$

where H is the Hessian matrix

$\mathbb{R}^{(n+1) \times (n+1)}$

黑森矩阵定义为导数矩阵

牛顿法的缺点是在高维问题中，如果 θ 是一个向量，那么反转它的成本将会极高，经验法则，如果小于五十个参数可以选择牛顿法迭代。