

04

2025.9.13开始lecture4的学习。

感知机模型以及广义线性回归模型 (GLM)

激活sigmoid函数

$$g(x) = \begin{cases} 1 & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases}$$

$$h_{\theta}(x) = g(\theta^T x)$$

感知器的参数更新：

$$\theta_j = \theta_j + \alpha(y^{(i)} - h_{\theta}(x^{(i)}))x_j^{(i)}$$

通过改变 θ 本质上就是旋转坐标轴，更新分界线。

但其只有几何上的解释，难以达成在概率上的解释，因此应用较小

指数族(Exponential Family)

指数族是一种概率模型：

$$P(y; \eta) = b(y) \exp[\eta^T T(y) - a(\eta)] \quad \eta \text{指的是自然参数}$$

$T(y)$ 为 y 的充分统计量

$a(\eta)$ 为对数分割函数

为什么采取指数族（指数族性质）：

1.在极大似然估计中，该函数为凸函数

2.对于每个分布， y 的期望值是 $\frac{\partial a(\eta)}{\partial \eta}$

3.每个分布的方差为 $\frac{\partial a(\eta)}{\partial \eta}$ 的二阶导

若有真实连续数据任务，则用高斯概率密度

若有分布任务则用伯努利概率密度

若有离散值则用泊松分布

GLM


GLM 有些像指数族的自然延伸

假设：

1. $y|x; \theta$ ：为指数族

2. $\eta = \theta^T x, \theta \in \mathbb{R}^n$

3.假设给我们一定的 x 进行预测，我们将输出其期望值。



通过线性模型输出一个 η ，再通过分布函数去计算其期望值。

然后通过梯度下降法去学习 θ 参数，最大化概率密度函数的对数

学习过程为： $\theta_j = \theta_j + \alpha(y^{(i)} - h_\theta(x^{(i)}))x_j^{(i)}$ 等同于感知机模型的损失函数。

$\eta \rightarrow$ 自然参数

$E[y;\eta] = g(\eta) \rightarrow$ 规范响应函数

其反函数为规范连接函数

该模型有三个参数：


1. 模型参数 θ 这是通过学习获得的
2. 自然参数 η
3. 规范参数 ϕ, μ, σ

softmax regression/交叉熵最小化

在这个问题中假设为多分类问题

多分类问题中label y 会设置成类似于独热编码。

在这里面可以将 θ 设置为一个矩阵，在不同的 θ 组中，可以有效的将这个都分类好（可以简易为，多次循环回归得出参数并接到矩阵当中）



学习方法就是为使得两个分布之间交叉熵最小

$$\begin{aligned}
 \text{Cross Entropy}(P, \hat{P}) &= - \sum_{y \in \{0,1,2\}} p(y) \log \hat{p}(y) \\
 &= - \log \hat{p}(y_0) \\
 &= - \log \frac{e^{\theta_0^T x}}{\sum_{i \in \{0,1,2\}} e^{\theta_i^T x}}
 \end{aligned}$$