

GDA (高斯判别分析)

在此之前我们学习的都是判别式学习算法，今天开始学习生成式学习算法。

相比于logistic 回归，高斯判别分析将会简单一些同时某些情况下会更有效，之后我们会学习朴素贝叶斯。

在前面所学的回归中，我们都是通过梯度下降法去寻找一条足以分开二者的线性函数。

生成式学习算法没有去寻找这一条直线，划清两者的边界线，然后判断新的更接近于哪一个。

分类算法：去寻找 $P(y|x)$

生成算法：寻找 $P(x|y)$

$P(y)$ 称为先验概率

通过贝叶斯规则： $P(y = 1|x) = \frac{P(x|y=1)P(y=1)}{P(x)}$

因此得： $P(x) = P(x|y = 1)P(y = 1) + P(x|y = 0)P(y = 0)$

GDA模型

其中 $x \in \mathbb{R}^n$,同时并不需要 $x_0 = 1$

关键假设： $P(x|y)$ 的分布是多元高斯分布(多元正态分布)

$\lambda \sim N(\vec{\mu}, \sigma)$

$E(Z) = \mu$

高斯密度函数如下所示：

$$P(z) = \frac{1}{(2\pi)^{\frac{1}{2}}|\sigma|^{\frac{1}{2}}} \exp\left(-\frac{(x-\mu)^T \sigma^{-1}(x-\mu)}{2}\right)$$

$$P(x|y=0) = \frac{1}{(2\pi)^{\frac{1}{2}}|\sigma|^{\frac{1}{2}}} \exp\left(-\frac{(x-\mu_0)^T \sigma^{-1}(x-\mu_0)}{2}\right)$$

$$P(x|y=1) = \frac{1}{(2\pi)^{\frac{1}{2}}|\sigma|^{\frac{1}{2}}} \exp\left(-\frac{(x-\mu_1)^T \sigma^{-1}(x-\mu_1)}{2}\right)$$

$$P(y) = \phi^y(1-\phi)^{1-y}$$

假设有如下训练集：

$$(x^{(i)}, y^{(i)})_{i=1}^m$$

构造其似然函数(在分类问题中选择 θ 假设其为条件似然函数)：

$$\begin{aligned} \ell(\phi, \mu_0, \mu_1, \sigma) &= \prod_{i=1}^m P(x^{(i)}, y^{(i)}, \phi, \mu_0, \mu_1, \sigma) \\ &= \prod_{i=1}^m P(x^{(i)}|y^{(i)})P(y^{(i)}) \end{aligned}$$

因此使用最大似然估计函数：


$$\begin{aligned} & \max_{\phi, \mu_0, \mu_1, \sigma} \ell(\dots) \\ & \text{同时显而易见 } \phi = \frac{\sum_{i=1}^m y^{(i)}}{m} \\ & \mu_0 = \frac{\sum_{i=1}^m x^{(i)} \langle \text{if } y^{(i)} = 0 \rangle}{\text{number}(y^{(i)} = 0)} \end{aligned}$$

协方差矩阵确定该椭圆形的走向。

接下来若要做出预测行为，即求出： $\max_y P(y|x) = \operatorname{argmax}_y \frac{P(x|y)P(y)}{P(x)}$

但因为已知 $P(x)$ 分布函数，因此其为一个常数，所以即求 $\operatorname{argmax}_y P(x|y)P(y)$


如果为了输出一个概率，那么需要将概率归一化之后进行输出。



比较GDA与Logistic回归


在GDA两种的交界处，难以界定其具体为哪一类。

如果将概率归一化之后会发现其概率最终会形成一个sigmoid函数：



Logistic回归和GDA都是在应用S型函数，这两种算法都提出了不同的决策边界。

但是为了比较二者的优劣，



相比而言，GDA提出了更为苛刻的假设。因此其要根据模型实际情况去判断自己使用哪一种算法。

若假定概率服从泊松分布或者是其他指数族，那么需要再次进行分析，但是如果是Logistic回归，则不需要考虑其是否符合那些指数族，但是对于逻辑回归的参数计算将会占用更多的时间，需要多次迭代，在GDA中，仅需要计算其协方差矩阵。

朴素贝叶斯

exp: 垃圾邮件分类

如何将邮件表示为特征向量，表示某个单词是否在邮件中存在，将邮件表示为一个伯努利的向量。

$$x \in \{0, 1\}^n$$

因此会有 $x_i = \{1, 0, \dots\}$

因此 x 会有 2^{10000} 种可能

链式法则(第二行是通过条件独立假设)：

$$\begin{aligned} P(X_1, X_2, \dots, X_{10000} | y) &= P(X_1 | y) P(X_2 | y, X_1) \dots P(X_{10000} | y, X_1, X_2, \dots, X_{9999}) \\ &= P(X_1 | y) P(X_2 | y) \dots P(X_{10000} | y) \end{aligned}$$

该模型参数：

$$\phi_{j|y=1} = P(x_j = 1 | y = 1)$$

$$\phi_{j|y=0} = P(x_j = 1 | y = 0)$$

$$\phi_j = P(y = 1)$$

接下来构建最大似然函数：

$$\ell(\phi_y, \phi_{j|y}) = \prod_{i=1}^m P(x^{(i)}, y^{(i)}; \phi_y, \phi_{j|y})$$

Joint likelihood:

$$\mathcal{L}(\phi_y, \phi_{j|y}) = \prod_{i=1}^m P(x^{(i)}, y^{(i)}; \phi_y, \phi_{j|y})$$

MLE:

$$\phi_y = \frac{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 1\}}{m}$$
$$\phi_{j|y=1} = \frac{\sum_{i=1}^m \mathbb{1}\{x_j^{(i)} = 1, y^{(i)} = 1\}}{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 1\}}$$

Stanford

但是其弊端为，在某些情况下会出现为0的方程，因此应当引入拉普拉斯平滑去修正。