

## 支持向量机

假设数据为线性可分

我们目的是最大化间隔，即  $\min \eta = y_i(\omega^T x_i + b)$

同时:  $\max \Lambda = \frac{\eta}{\|\omega\|}$

我们的目标就是:  $\max_{\omega, b} \Lambda$

subject to:  $y_i(\omega^T x_i + b) \geq 1$

同时转换优化目标，如若优化曲线已经确定，那么就去选择其最大软距离  $\max \frac{1}{\|\omega\|}$

即  $\min \frac{1}{2} \|\omega\|^2$

我们假设:  $x^{(i)} \in \mathbb{R}^{100}$

$\omega = \sum_{i=1}^M \alpha_i y^{(i)} x^{(i)}$  该假设正确。可以通过由多个训练集样本点确定决策边界，假设只有两个点，那么你的决策边界就已经确定了。

$\omega$  是一个垂直于决策边界的一个向量

因此目标函数变为：

$$\begin{aligned} \min & \frac{1}{2} \left( \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} \right)^T \left( \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} \right) \\ &= \min \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j x^{(i)T} x^{(j)} y^{(i)} y^{(j)} \\ &= \min \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j < x^{(i)}, x^{(j)} > y^{(i)} y^{(j)} \end{aligned}$$

subject to :

$$y^{(i)} \left( \left( \sum_{j=1}^M \alpha_j y^{(j)} x^{(j)} \right) x + b \right) \geq 1$$

$$y^{(i)} \left( \left( \sum_{i=1}^M \alpha_i y^{(i)} x^{(i)} \right) + b \right) \geq \Lambda$$

同时定义内积:  $< x_i, x_j >$

对偶优化问题

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j y^{(i)} y^{(j)} \alpha_i \alpha_j \langle x^{(i)}, x^{(j)} \rangle$$

$$s.t. \alpha_i \geq 0$$

$$\sum y^{(i)} \alpha_i = 0.$$

"Dual optimization problem."

对于一个新的预测:  $h_{\omega,b} = g(\omega^T x_i + b)$

## kernel核方法

<1>已经表示出 $\omega$ 由 $\langle x^{(i)}, x^{(j)} \rangle$ 决定, 那么可以将此转换到更高的维度

<2>构造映射关系 $x \rightarrow \phi(x)$ , 可以由低维转到高维

<3>找到一种计算 $K(x, z) = \phi(x)^T \phi(z)$

<4>替代算法中的 $\langle x, z \rangle$

但是会增加时间复杂度。

比如说在显示映射中(如多项式映射): 时间复杂度将会增加

但如果是直接设置一个核函数:  $K(x, z) = g(x, z)$  那么就可以直接绕过 $\phi(x)$ 和 $\phi(z)$

## 如何设定核函数

①如果 $x, z$ 是相近的, 那么他们内积将会极大

②如果 $x, z$ 是不同的, 那么内积将会小一些

高斯核函数:  $K(x, z) = \exp(-\frac{\|x-z\|^2}{2\sigma^2})$  根据 $x, z$ 距离决定核函数大小

基本满足: ①  $K(x, x) = \phi(x)^T \phi(x) \geq 0$

Does there exist  $\phi$  s.t.  $k(x, z) = \phi(x)^T \phi(z)$

$k(x, x) = \phi(x)^T \phi(x) \geq 0.$

---

Let  $\{x^{(1)}, \dots, x^{(n)}\}$  be  $n$  points.

Let  $K \in \mathbb{R}^{n \times n}$ . "kernel matrix"

$k_{ij} = k(x^{(i)}, x^{(j)})$

Given any vector  $z$ ,


$$z^T K z = \sum_i \sum_j z_i k_{ij} z_j$$

$$= \sum_i \sum_j z_i \phi(x^{(i)})^T \phi(x^{(j)}) z_j$$

$$= \sum_i \sum_j z_i \sum_k (\phi(x^{(i)}))_k (\phi(x^{(j)}))_k z_j$$

## 软间距算法 (L1算法)

在模型中，我们假设数据都是线性可分的，但是很难做到



在上述中  $y^{(i)}(\omega^T x^{(i)} + b)$  为几何距离

因此可放松假设:  $y^{(i)}(\omega^T x^{(i)} + b) \geq 1 - \xi_i$

同时增添限制:  $\xi_i \geq 0$

因此目标函数改为:  $\min \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i$