

笔记

主要内容在于学习的假设，偏差，泛化的原因，收敛性。

假设 (Assumption)

两个假设：


①存在如下分布 D ： $(x, y) \sim D$, 我们的数据是来源于同一分布。

②所有样本都是独立采样

偏差方差

偏差是估计参数离实际参数的距离

方差是估计参数距离其自身的距离。当我们采取正则化的时候，方差将会减少。




统计有效性：当 $m \rightarrow \infty$ $var[\hat{\theta}] \rightarrow 0$ $\hat{\theta} \rightarrow \theta$, 则称其为一致性算法。 $E[\hat{\theta}] = \theta$

如果一个模型偏差极大，即为不具备有效性的算法，即使数据量极大也会有极大的偏差。

Fighting Variance:

①提高数据量使得, $m \rightarrow \infty$

②正则化 (但会导致有效性丧失一点)



这是在给定数据集中分布情况， g 为真实分布， H 为通过学习算法可以得到的分布 $\hat{h}$ ，是该空间中一个，该空间内因为噪声而导致的误差 $\epsilon(h)$ 称为风险和泛化误差。


$\epsilon(h) = E_{(x,y) \sim D}[l\{h(x) \neq y\}]$ ，这是趋于无穷的情况下。

$\hat{\epsilon}$ 称为经验风险即我们自己有限数据集中，犯错的概率。

$\epsilon(g)$ 称为贝叶斯误差，即为不可避免的误差（比如说有的相同 x 但是输出不同 y ）

$\epsilon(h^*) - \epsilon(g)$ 称为近似误差(Approximation Error),可以理解为模型之间的误差

$\epsilon(\hat{h}) - \epsilon(h^*)$ 称为估计误差(Estimation error)，这是数据的误差



显然， $\epsilon(\hat{h}) = \text{贝叶斯误差} + \text{近似误差} + \text{估计误差}$

$$\begin{aligned} E(h) &= \text{Estimation Error} + \text{Approx Error} + \text{Irreducible Error} \\ &= \underbrace{\text{Est Var} + \text{Est Bias}}_{\text{Bias}} + \underbrace{\text{Approx Error}}_{\text{Var}} + \underbrace{\text{Irreducible Error}}_{\text{Irred u}} \end{aligned}$$

对于高偏差:

①更换模型, 增大 h , 比如说增添正则化

经验风险最小化(ERM)

ERM是一种学习算法

目标函数为: $\arg \min_{h \in H} \frac{1}{M} \sum_{i=1}^M \{h(x^{(i)}) \neq y^{(i)}\}$

研究的两大问题:

① $\hat{\epsilon}(h)$ vs $\epsilon(h)$

② $\epsilon(\hat{h})$ vs $\epsilon(h^*)$

两大工具去解决: ①联合约束 ②霍夫丁不等式 (Hoeffding)

联合约束


假设有如下事件 $A_1, A_2, \dots, A_n$ 并不要求独立, 那么 $P(A_1 \cup A_2 \cup \dots \cup A_n) \leq P(A_1) + \dots + P(A_n)$

霍夫丁不等式

假设有 $Z_1, Z_2, \dots, Z_m \sim \text{Bino}(\phi)$, 设 $\hat{\phi} = \frac{1}{m} \sum_{i=1}^m Z_i$

假设有 $r > 0$, 称为间距(margin)

$$P[|\hat{\phi} - \phi| > r] \leq 2 \exp(-2r^2 M)$$



$$P[\exists h \in \mathcal{H} \cdot |\hat{\epsilon}_h - \epsilon(h)| > \gamma] \leq K \cdot 2 \exp(-2\gamma^2 m)$$

$$P[\forall h \in \mathcal{H} \cdot |\hat{\epsilon}_h - \epsilon(h)| < \gamma] \geq 1 - \underbrace{2K \exp(-2\gamma^2 m)}_{\delta}$$

结论如下：对于样本量M做出该约束

$$\text{Fix } \gamma, \delta > 0$$

$$M \geq \frac{1}{2\gamma^2} \log \frac{2K}{\delta}$$